

李赢洲

Yingzhou Li

大模型应用工程实习 | RAG / Agent / GraphRAG / FastAPI 工程化

邮箱: 13054111853@163.com GitHub: github.com/20082123

个人定位

电子信息硕士在读, 主攻大模型应用工程落地。具备 RAG/GraphRAG、FastAPI 服务、异步任务队列、本地模型调用优化和 LLM 批量评测实践, 熟悉从文档解析、检索增强、任务调度、模型调用到部署评测的工程化流程。

教育背景

贵州大学

2024.09 – 至今

电子信息 (硕士); 研究方向: 随机配置网络、强化学习; 华为杯中国研究生数学建模竞赛国家二等奖; 校三等奖学金。

防灾科技学院

2020.09 – 2024.06

信息管理与信息系统 (本科); 两次校二等奖学金。

专业技能

- **大模型后端工程化**: LLM API / 本地模型接入、FastAPI、asyncio、异步任务队列、模型调用缓存、异常兜底、Docker Compose。
- **RAG 与文档处理**: RAG / GraphRAG、Prompt 约束、结构化输出、pdfplumber、PaddleOCR、UnstructuredLoader、Milvus、混合检索、ReRanker、Neo4j。
- **后端与数据链路**: Python、SQLite、Worker 异步处理、批量入库、JSON 清洗、日志分析、脚本自动化。
- **评测与问题定位**: LLM/RAG 批量并发评测、指标口径设计、特征泄漏审查、失败原因分析、业务约束校验。

实习项目经历

焊接工艺智能决策平台

上海波士内智能科技有限公司

AI 后端服务 / 工业文档 RAG / GraphRAG 数据链路

- 面向工业标准 PDF 表格多、版式复杂、人工查询效率低的问题, 参与问答系统后端链路搭建, 负责文档解析服务、RAG 检索、异步任务队列、图谱同步和本地模型调用优化。
- 设计“逐页检测 + 动态路由”机制, 文本页走 pdfplumber, 低字符密度或复杂表格页切换 PaddleOCR; 7 页混合工业 PDF 解析耗时由 21.3 分钟降至约 13 秒, MVP Pipeline 控制在 1.5 分钟内。
- 将大文档同步处理改为 FastAPI + SQLite + 独立 Worker 异步队列, 避免上传请求长时间阻塞, 并为状态查询、失败重试和横向扩展 Worker 预留接口边界。
- 优化 LightRAG 本地模型调用链路, 设计 CachedLocalLLMProxy 常驻单例缓存; 单 Chunk 推理延迟由 144s 降至 1.2s, VRAM 峰值占用下降 96%。
- 开发 neo4j_syncer 图谱同步模块, 使用 UNWIND 批量写入节点与边, 吞吐达到 680+ 节点/秒, 打通 RAG 检索结果到 GraphRAG 关系数据的后端链路。

TKE 电梯虚拟教练系统

上海波士内智能科技有限公司

批量评测脚本 / 数据链路校验 / RAG 效果分析

- 围绕真实业务时间线审查工单、运行日志与维修记录的数据可见时间, 发现“维修描述”字段存在时间轴与目标泄漏; 剔除泄漏特征并重切窗口后, 建立 68.4% 的真实可靠模型基准。
- 编写 Python 自动化评测脚本, 对 1500+ 验证样本进行批量并发评测和 JSON 结果清洗, 按 ErrorCode、Component 精确匹配和统计特征召回分析 RAG 融合效果。
- 将评测流程拆为样本读取、模型调用、结果解析、指标统计和失败样本归因等环节, 沉淀可复用的离线评测链路, 便于后续对不同检索策略和 Prompt 版本做对比。

个人实践与项目

AI News Weekly: AI 资讯自动邮件系统

github.com/20082123/ai-news-weekly

使用 Python 实现资讯整理、结构化排版、邮件模板生成和自动发送流程, 形成“信息整理 - 摘要改写 - 邮件生成 - 自动发送”的轻量 workflow。

GEO Radar: AI 平台品牌召回与回答偏好评测

使用 Playwright + asyncio 自动化采集 AI 平台在汽车推荐类 Query 下的回答, 并设计 LLM 结构化抽取流程, 将自然语言回答转为品牌、车型、预算、推荐理由等字段, 统计品牌出现频次、推荐排序和回答稳定性。